

Введение в информационный поиск

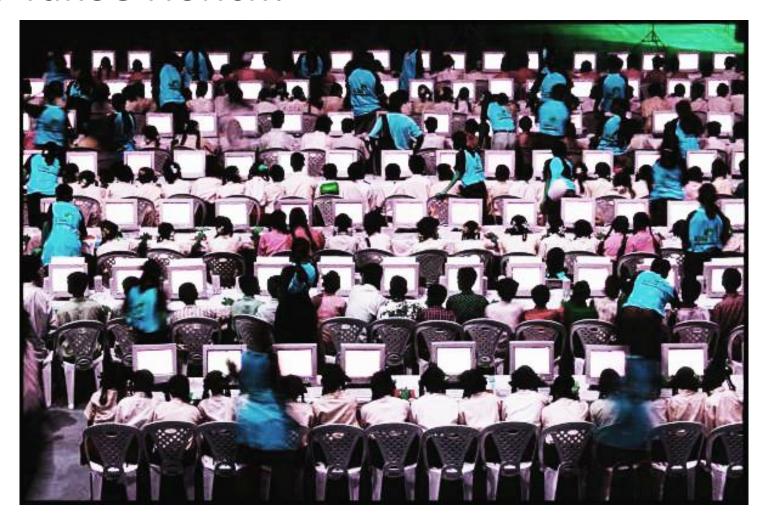
Сергукова Юлия, программист отдела инфраструктуры проекта Поиск@Mail.Ru



Что такое Поиск?



Что такое Поиск?





Что такое Поиск?





Поиск@Mail.Ru



рики-тики-тави

Найти

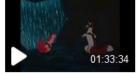
Интернет

Картинки

Видео Новости

Видео по запросу «рики-тики-тави»

3 тыс. результатов









×

Сборник Мультфильмов Рикки-Тикки-Тави - Рики-Тики-Тави

5 сентября 2013

Youtube

28 мая 2012

РИКИ. ТИКИ. **ТАВИ**. 1975 г. СССР

Ok.ru

7 сентября 2015

Рики -(1965)Ok.ru

15 июл:

Mail.ru

Рикки-Тикки-Тави — Youtube.com №

youtube.com/watch?v=ar-lv03EIXI

Мультики студии Союзмультфильм, 3 196 020 просмотров

Мультики: Рикки тикки тави. Советский мультфильм для детей по рассказу Р. Киплинга. Нажми лайк, если любишь советские мультфильмы. Добрые советски...

👓 Сказка Рикки Тикки Тави - Редьярд Киплинг 🔮

deti-online.com/skazki/skazki-

Рикки Тикки Тави - сказка Киплинга. Рикки Тикки Тави читать онлайн или скачать в формате doc или pdf.







Рикки-Тикки-Тави

«Рикки-Тикки-Тави» — рассказ из «Книги джунглей» Редьярда Киплинга, а также имя главного героя этого рассказа. Википедия

Год первого издания: 1893 Авторы: Редьярд Киплинг

Сообщить об ошибке Википедия



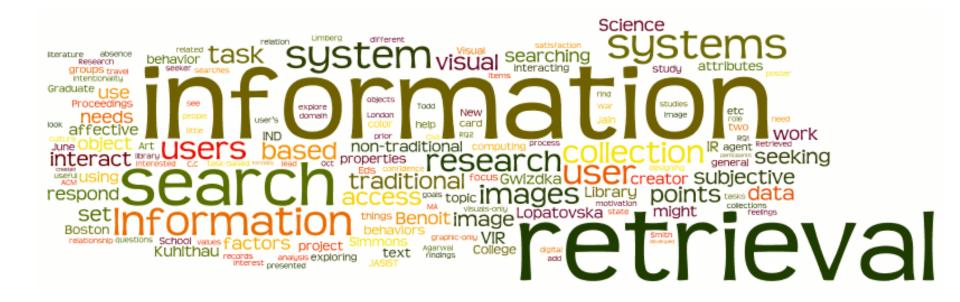
Поиск@Mail.Ru

- Текстовый поиск
- Картинки
- Видео
- Новости
- Ответы
- Карточка «быстрого ответа»

а еще:

- Приложения
- Обсуждения
- и многое другое







Что такое информационный поиск

Информационный поиск — процесс поиска неструктурированной документальной информации, удовлетворяющей информационные потребности пользователя



Примеры информационных поисков

- grep
- find
- SQL
- Maps.Me / Google Maps
- Запросы в багтрекере
- Поиск по микроблогам
- Поиск по картинкам
- Вэб-поиск



Информационный поиск

Наука

- математические модели
- вычислительная лингвистика
- статистика и теорвер

Практика

- огромный объем данных
- KISS («keep it simple, stupid»)
- хаки практической реализации



Цель

«удовлетворение информационной потребности пользователя»



Цель

«удовлетворение информационной потребности пользователя»

У пользователя есть потребность в получении определенной информации

Цель – найти **релевантную** его запросу информацию



Входные данные

- корпус документов набор документов (текстов, изображений, новостных блоков и т.д.)
- ссылочная информация PageRank
- **обратная связь** запросы пользователей и клики в выдачу



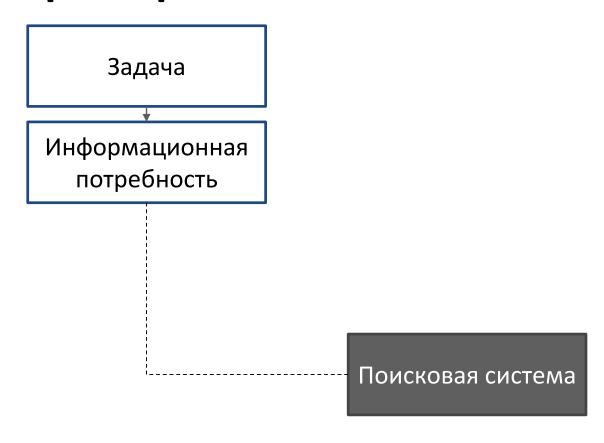
Задача

Поисковая система

Смерть («Плоский мир» Т.Пратчетта)







Смерть («Плоский мир» Т.Пратчетта)

Статья/обсуждение персонажа



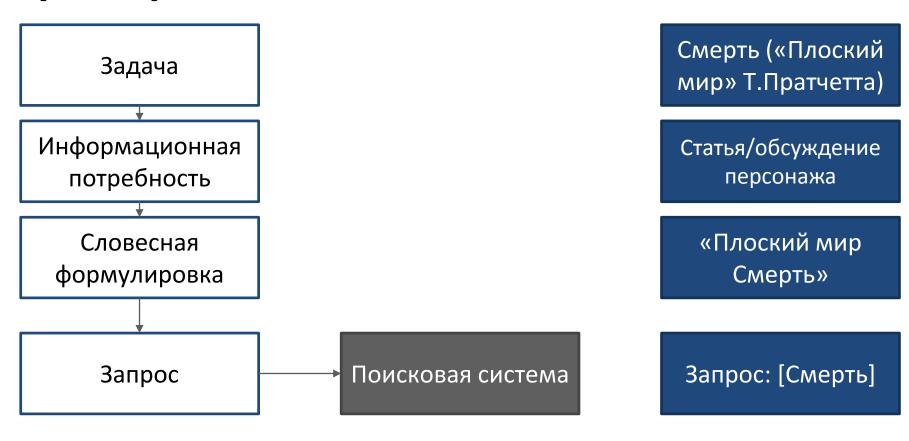


Смерть («Плоский мир» Т.Пратчетта)

Статья/обсуждение персонажа

«Плоский мир Смерть»











Что может пойти не так?



Что может пойти не так?

- Не поняли пользователя
 - Синонимы
 - Опечатки
 - Несодержательный запрос
- Нашли не то
 - Омонимы
 - Нет знаем нужный документ (непопулярные запросы)
 - Пользователь не согласен с результатами





Сложности обработки запросов от людей

- лингвистика: что написано в тексте
- запросы: что хотел пользователь
- статистика
- машинное обучение
- огромные объемы данных
- большие нагрузки
- пользовательский интерфейс
- форматы данных



Связанные задачи

- рекомендательные системы
- машинный перевод
- извлечение мнений
- распознавание и синтез речи
- семантический анализ текста
- диалог с пользователем
- и т.д.





Примеры поисковых систем

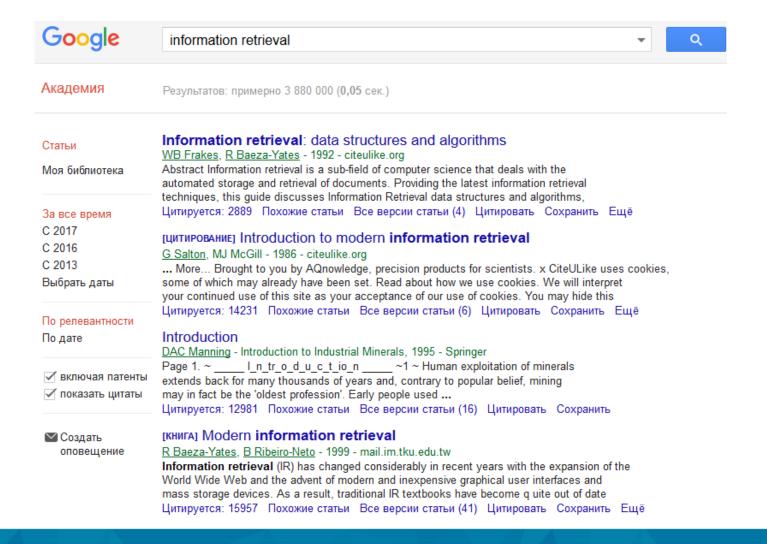


Южная Корея - Naver



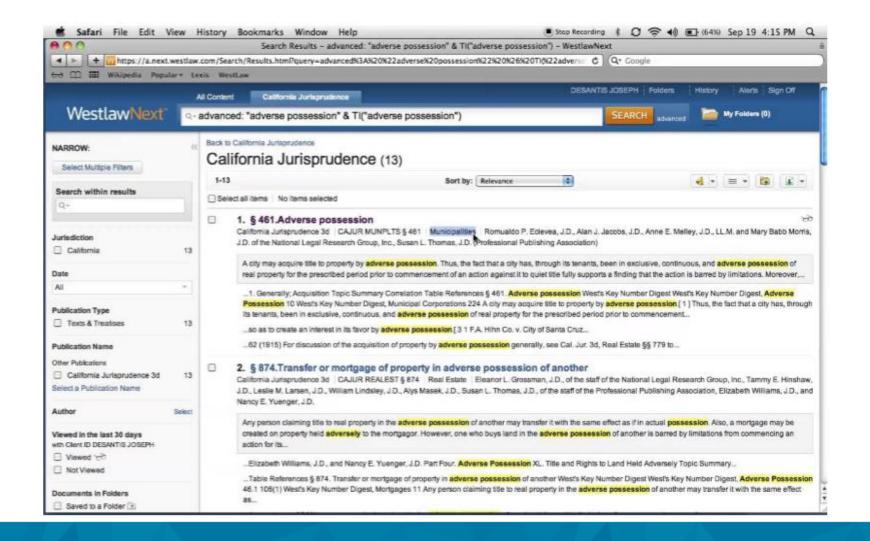


Google Scholar



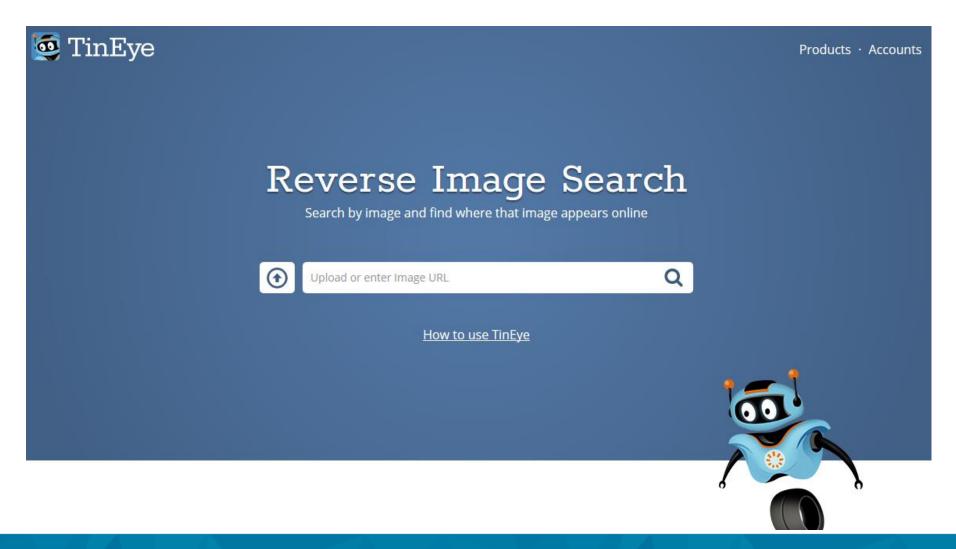


Westlaw



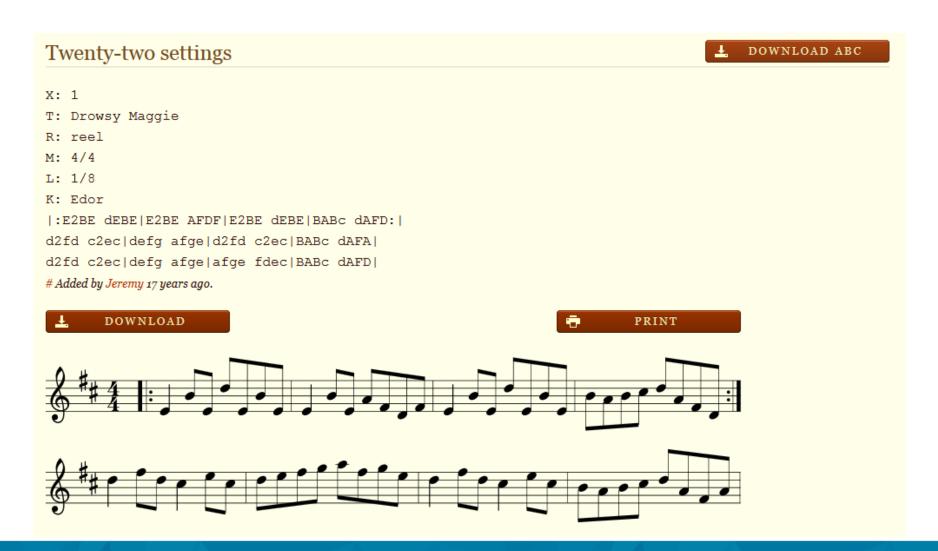


He-текстовый поиск. TinEye



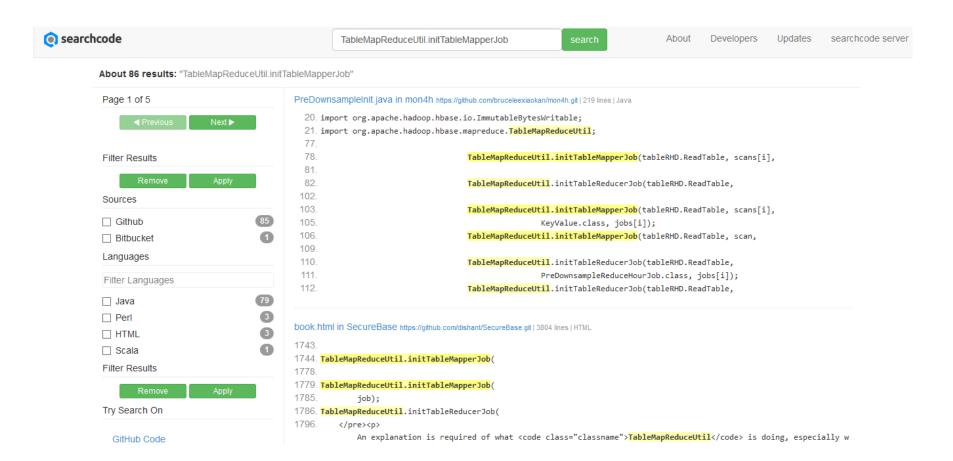


Не-текстовый поиск.



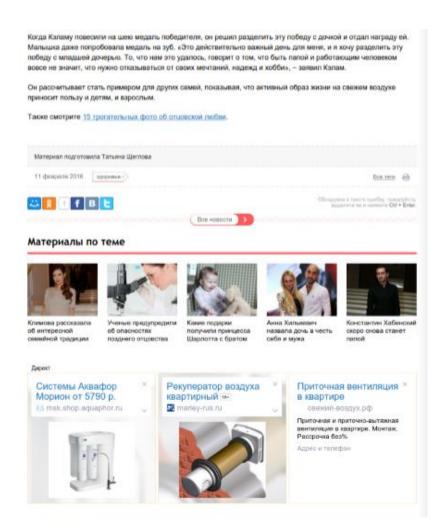


Специализированный поиск.





Контентные рекомендательные системы



Pandora's "Music Genome Project" explores the cold hard facts of how we interact with music

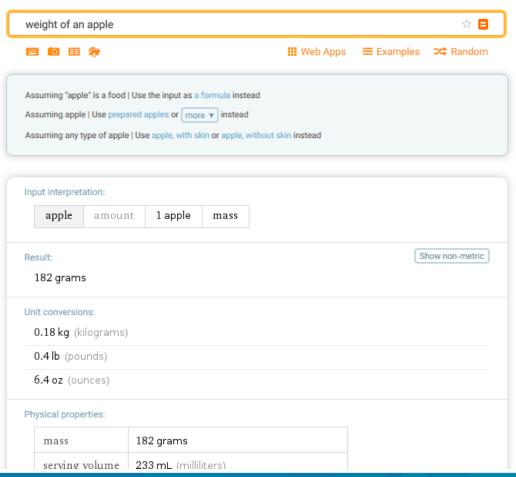
Twenty-five music analysts 'grade' 10,000 songs a month. It's a mountainous job, writes Rob Pegoraro, but the results will be serious business.





Поиск по структурированной информации и неструктурированным запросам







IBM Watson



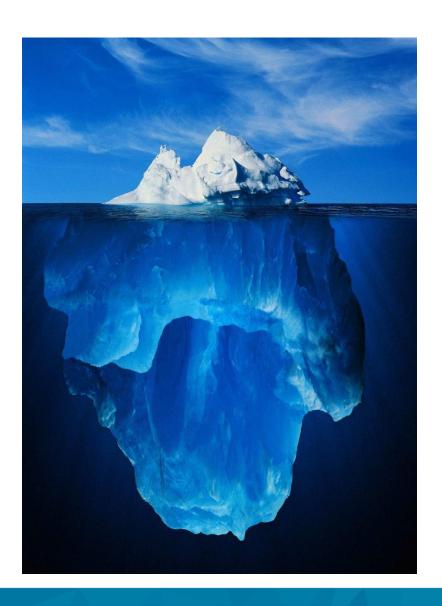


Обзор курса





Обзор курса





Преподаватели



Юлия Сергукова



Евгений Чернов



Андрей Мурашев



Владимир Гулин

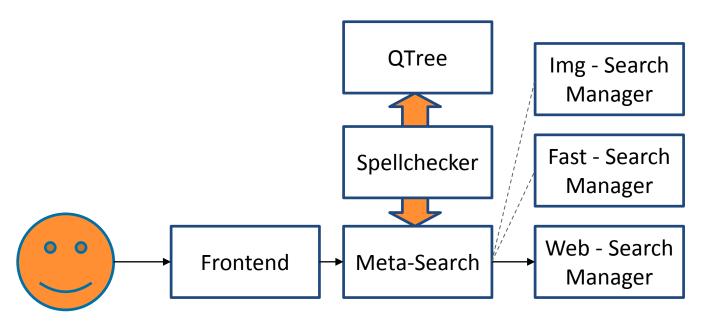


Как работает поиск



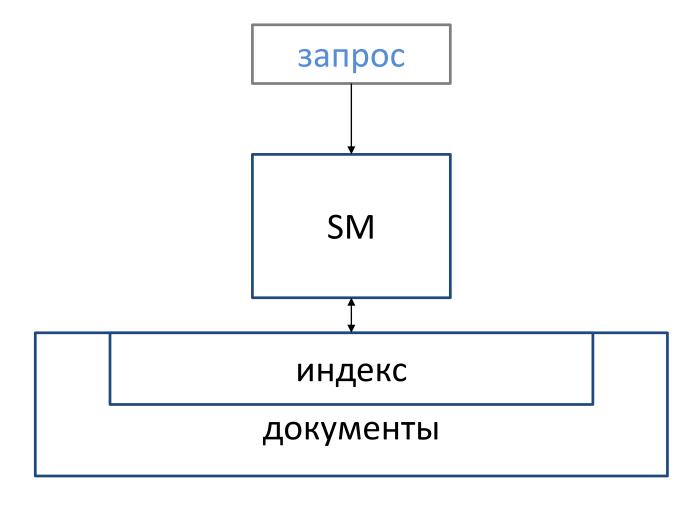






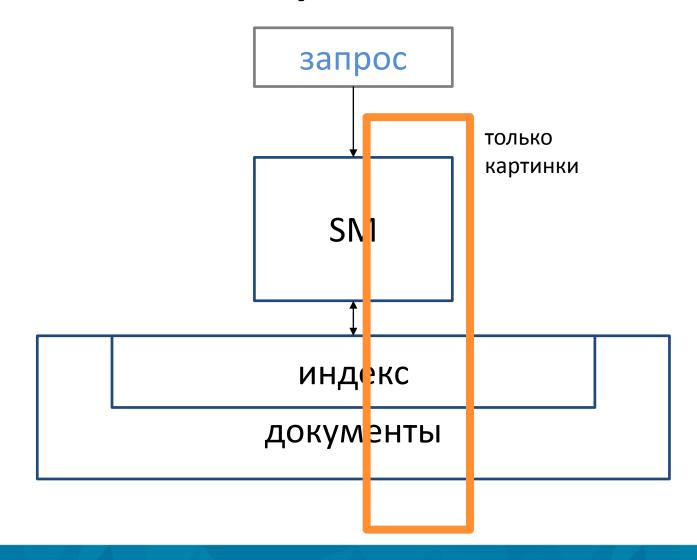


Немного о вертикалях

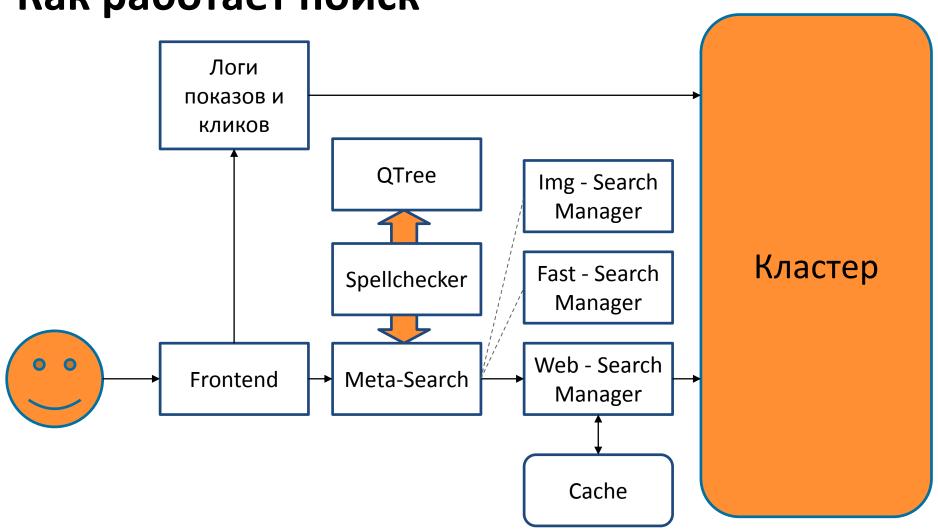




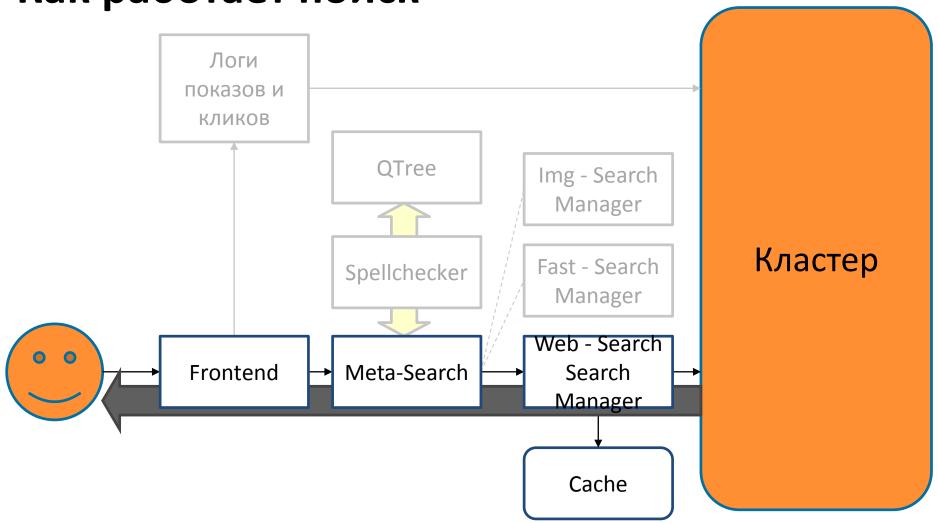
Немного о вертикалях













О чем мы будем говорить на лекциях

- 1. Поисковый спайдер (лекция 2)
- 2. Планировщик поискового спайдера (лекция 3)
- 3. Индексация (лекция 4) и оптимизация индекса (лекция 5)
- 4. Поиск дубликатов (лекции 6-7)
- 5. Антиспам и антипорн (лекции 8 и 9)
- 6. Микроразметка (лекция 10)
- 7. Сниппеты (лекция 11)
- 8. Исправление опечаток (лекция 12)
- 9. Саджесты и переформулировки (лекция 13)



О курсе

Основан на Introduction to information retrieval (Stenford)

https://nlp.stanford.edu/IR-book/pdf/irbookonlinereading.pdf

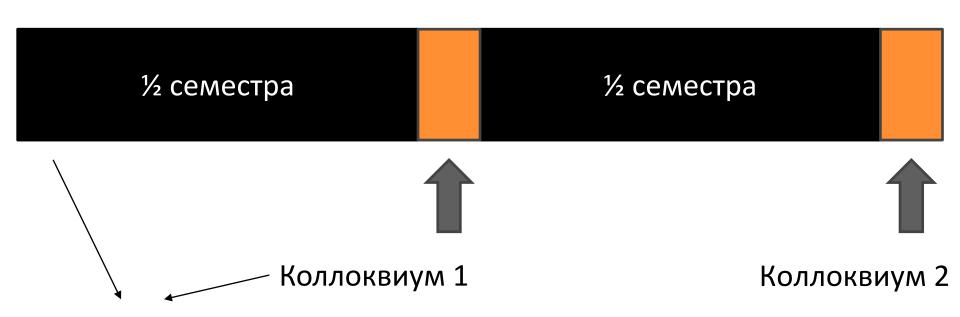
Читаем более 10 лет

Основной упор – на практическое применение

Делайте домашки!



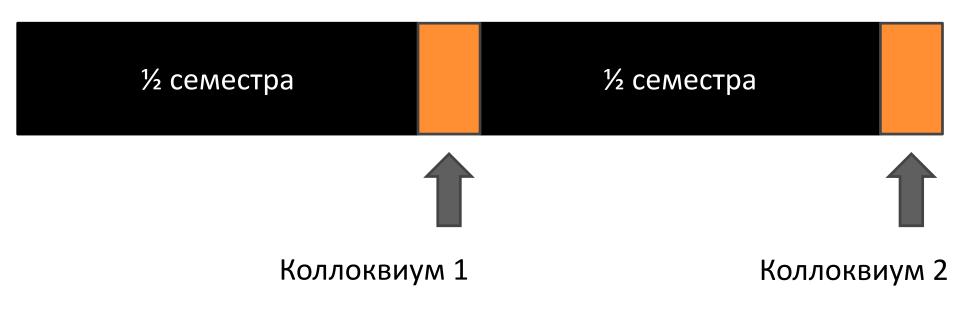
Структура курса



3 домашние работы коллоквиум (опционально, 0-10 баллов) порог выживания = 35 баллов



Структура курса



Весь курс: 6 домашних работ 2 коллоквиума (опционально, 0-20 баллов)

порог выживания = 60 баллов



Делайте домашки!

Для допуска к первому коллоквиуму нужно набрать пороговое значение баллов - 35.

Не набрали – прощаемся с вами в середине семестра.

Оценки

За что можно получить баллы:

- домашние работы
- активная работа на лекция и семинарах
- сдача коллоквиума

Оценки:

$$60 - 79 == «3»$$

$$80 - 94 == (4)$$



Домашние работы

- проверяются преимущественно автоматически
- списывание и/или непроходимая глупость 0 баллов
- дедлайн обычно 2 недели

2 недели	до конца курса
N баллов	N/2 баллов

Если что-то непонятно:

в первую очередь спрашивайте преподавателя, который который выдал домашку/читал лекции.



Блог – ваш друг

https://sphere.mail.ru/blog/view/40/

Зачем?

- Выкладываются лекции
- Перед семинаром даются указания
- Выкладываются домашки (и иногда результаты)
- Иногда бывают изменения в расписании



Лайки!



...а еще отзывы и посещаемость



Спасибо за внимание!

Не забудьте отметиться на сайте и оставить отзыв